

**Senac**

**Fecomércio  
Sesc**

## Data Science – Princípios e Técnicas

Abril  
2025



# Projeto de Ciência de dados

# Data Science



---

Em geral os projetos de data science envolvem as seguintes etapas:

- 1. Entendimento do negócio:** aqui são definidas as perguntas, o objetivo da análise de dados e o plano a ser seguido;
- 2. Compreensão dos dados:** etapa utilizada para coletar e explorar os dados, aumentando a compreensão sobre sua estrutura, atributos e contexto;

# Data Science

---

**3. Preparação dos dados:** após a análise exploratória, inicia-se o processo de limpeza, filtragem, estruturação, redução e integração dos dados;

**4. Modelagem dos dados:** envolve as tarefas de seleção dos dados, definição e construção do modelo;

# Data Science

---

5. **Validação do modelo:** os resultados gerados pelo modelo são avaliados, para verificar se a precisão obtida está satisfatória e coesa;

6. **Utilização do modelo:** após serem validados, os resultados dos modelos são utilizados e monitorados.

# Data Science

---

**Também vimos que: Os dados utilizados estão normalmente “sujos”**

Muitas vezes, as bases contêm dados incompletos, inconsistentes, corrompidos, duplicados ou em formatos inadequados, entre outros problemas. Portanto, é essencial a intervenção de um profissional capacitado para tratar esses dados antes de iniciar a análise propriamente dita.

# Data Science

---

A crescente geração de dados amplifica a necessidade de limpeza de dados eficiente, visto que a má qualidade dos dados implica custos significativos para as empresas, chegando a US\$ 12,9 milhões anualmente, conforme indicações da [Gartner](#).

# Data Science

---

Além do impacto financeiro, dados imprecisos demandam dos cientistas de dados até 60% do seu tempo em tarefas de limpeza e organização, ressaltando a importância de adotar ferramentas e estratégias proativas para assegurar a qualidade dos dados desde sua coleta.



# Data Science

---

**Mas como resolvemos esse problema?**

Com o processo de limpeza de dados!

# Data Science

---

## O que é Limpeza de dados?

A limpeza de dados, essencial no gerenciamento de qualidade, envolve identificar e corrigir erros ou inconsistências nos dados para garantir sua precisão, consistência e utilidade.

# Data Science

---

Esse processo é crucial pois o uso de dados brutos, sem tratamento, pode levar a decisões baseadas em informações imprecisas, prejudicando a eficácia operacional e estratégica das organizações.

# Data Science

---

Mas por que não podemos usar dados brutos em vez de gastar tanto tempo na limpeza de dados?

# Data Science



- **Entradas com erros ortográficos:** Erros de digitação e ortografia podem levar a erros de categorização.
- **Formatos inconsistentes:** Datas, números ou categorias podem ser representados de forma diferente no mesmo conjunto de dados.
- **Valores discrepantes e erros:** Entradas incomuns ou erradas podem levar a análises imprecisas.

# Data Science

---

- **Registros duplicados:** Dados redundantes podem levar a estatísticas e conclusões imprecisas.
- **Valores nulos ou ausentes:** Dados incompletos podem levar a lacunas na análise e a insights imprecisos e/ou limitados.
- **Dados imprecisos:** Informações incorretas ou desatualizadas podem levar a decisões imprecisas.

# Data Science



- **Unidades não padronizadas:** Diferentes unidades de medida podem criar problemas de inconsistência de dados, especialmente ao comparar ou agregar dados.
- **Dados incompatíveis:** Dados conflitantes de fontes diferentes podem causar discrepâncias integração de dados e análise.

# Data Science

---

## Principais técnicas de limpeza de dados

### Removendo duplicatas:

Como fazer: Utilize algoritmos para identificar e remover linhas duplicadas com base em atributos vitais selecionados.



# Data Science

---

## Tratamento de dados ausentes:

Como fazer: As opções incluem imputação, exclusão ou uso de algoritmos que podem lidar com valores ausentes. A imputação pode usar estratégias baseadas em média, mediana ou modelo, como k-NN.

# Data Science



---

## Corrigindo dados incorretos:

Como fazer: verificações de consistência e revisão manual, se necessário. Ferramentas de preparação de dados podem ajudar na correspondência de padrões e correções.

# Data Science



---

## Tratamento de valores discrepantes:

Como fazer: identifique valores discrepantes por meio de métodos estatísticos, como pontuação Z ou IQR, e decida se deseja limitá-los, transformá-los ou removê-los.

# Data Science

---

## Normalizando Dados:

Como fazer: aplique técnicas como dimensionamento mínimo-máximo, normalização de pontuação Z ou transformações de log.

# Data Science



## Validando a consistência dos dados:

Como fazer: Crie regras de validação para verificar relacionamentos e consistência entre atributos.

# Data Science

---

## Transformando Dados:

Como fazer: usar transformações de dados como codificação de dados categóricos ou criação de termos de interação com base em necessidades analíticas.

# Data Science

---

Mais detalhes:

<https://www.astera.com/pt/type/blog/data-cleansing/>

# Um pouco de estatística



# Data Science



---

Nos últimos anos, houve um crescimento exponencial no volume de dados gerados pela humanidade, o que gerou uma demanda crescente por profissionais capazes de extrair informações e tomar decisões fundamentadas com base nesses dados.

# Data Science

---

Um aspecto crucial ao trabalhar com dados é a habilidade de descrevê-los, resumi-los e representá-los visualmente. A estatística descritiva é uma ferramenta essencial nesse processo, utilizando duas abordagens principais:

# Data Science

---

- **A abordagem quantitativa**, que descreve e resume os dados numericamente.
- **A abordagem visual**, que ilustra os dados por meio de gráficos e visualizações.

# Data Science



---

Na análise quantitativa, destacamos:

- A **tendência central** informa sobre os centros dos dados. Medidas úteis incluem a média, mediana e moda.
- A **variabilidade** informa sobre a dispersão dos dados. Medidas úteis incluem variância e desvio padrão.

# Data Science

---

- A **correlação** (ou **variabilidade conjunta**) informa sobre a relação entre um par de variáveis em um conjunto de dados. Medidas úteis incluem a covariância e o coeficiente de correlação.

# As medidas de tendência central

# Data Science

---

Antes de começarmos a estudar o princípios de estatísticas baixe o seu projeto e crie um banco sqlite localmente.

# Data Science



---

Média:

A média aritmética, ou simplesmente média, de um conjunto de valores é a medida de centro encontrada somando todos os valores do conjunto e dividindo pelo número de valores. Assim:

$$\text{Média} = \frac{\text{soma dos valores}}{\text{total de observações}}$$



# Data Science

---

**Exemplo 1:** Determine a média de um dos atributos no banco.

# Data Science



**Obs:** Existem outras médias, porém cada uma delas é usada em situações específicas. A saber:

- **Média Ponderada:** Você deve usar uma média ponderada quando deseja atribuir mais importância a alguns números em um conjunto de dados do que a outros. Isso é útil em cenários onde um evento pode ter vários resultados positivos ou negativos, e a magnitude desses resultados varia.

# Data Science

---

- **Média Harmônica:** A média harmônica é calculada como o número de valores dividido pela soma do inverso de cada valor. É apropriada quando os dados representam grandezas que são inversamente proporcionais, como taxas.

# Data Science

---

- **Média Geométrica:** A média geométrica é calculada como a raiz  $N$ -ésima do produto de todos os valores, onde  $N$  é o número de valores. É útil quando os dados estão em uma escala multiplicativa, como em situações envolvendo crescimento ou taxa de variação entre diferentes unidades de medida.

---

## Mediana

A **mediana** da amostra é o elemento central de um conjunto de dados ordenado (crescente ou decrescente). Se o número de elementos  $n$  do conjunto de dados for ímpar, então a mediana é o valor na posição do meio. Se  $n$  for par, então a mediana é a média aritmética dos dois valores no meio

# Data Science

---

**Exemplo 2:** Encontre a mediana de um dos atributos no banco.

# Data Science



---

**Importante:** A principal diferença entre o comportamento da média e da mediana está relacionada aos valores extremos (outliers) do conjunto de dados. De uma maneira geral:

# Data Science

---

- Se você adicionar um valor discrepante maior do que a média em um conjunto de dados, a média aumentará, mas o valor da mediana vai sofrer pouca influência.
- Se você remover um valor discrepante de um conjunto de dados, a média diminuirá, mas o valor da mediana vai sofrer pouca influência.



# Data Science

---

Agora vamos dividir o conjunto original em subconjuntos com características específicas e observar o que acontece com a média. Esse processo, conhecido como **estratificação**, consiste em separar os dados em subgrupos (ou estratos) que compartilham características semelhantes.

# Data Science

---

Ao analisar cada estrato individualmente, podemos identificar variações internas e entender como cada subgrupo contribui para o comportamento geral dos dados, resultando em análises mais detalhadas e representativas.

# Data Science



---

**Exemplo 3:** A média é mantida quando analisamos tipos de cartões diferentes?

# Data Science

---

## Moda

A **moda** da amostra é o valor no conjunto de dados que ocorre com mais frequência. Se não houver um único valor desse tipo, o conjunto será multimodal, pois possui vários valores modais.

# Data Science

---

## Exemplo 4:

# Data Science



---

## Medidas de Localização

O percentil  $p$  da amostra é o elemento no conjunto de dados tal que  $p\%$  dos elementos no conjunto de dados são menores ou iguais a esse valor. Além disso,  $(100 - p)\%$  dos elementos são maiores ou iguais a esse valor. Se houver dois desses elementos no conjunto de dados, o percentil  $p$  da amostra é a média aritmética deles.

# Data Science

---

- O primeiro quartil  $Q1$  é o percentil 25 da amostra. Ele divide aproximadamente 25% dos menores itens do restante do conjunto de dados.
- O segundo quartil  $Q2$  é o percentil 50 da amostra, também conhecido como a mediana. Aproximadamente 25% dos itens situam-se entre o primeiro e o segundo quartis, e outros 25% entre o segundo e o terceiro quartil.

# Data Science

---

- O terceiro quartil Q3 é o percentil 75 da amostra. Ele divide aproximadamente 25% dos maiores itens do restante do conjunto de dados.



# Data Science

---

## Exemplo 6:

# Dúvidas?

---

